

# CONCEPTION D'UN PROGRAMME DE THREADING PAR DOUBLE PROGRAMMATION DYNAMIQUE

## Résumé

La prédiction de la structure 3D d'une protéine à partir de sa séquence d'acides aminés est un défi majeur en biologie structurale. Ce projet présente l'implémentation, en Python, de l'algorithme THREADER, une méthode de reconnaissance de repliements par double programmation dynamique. L'implémentation évalue la compatibilité entre une séquence et une structure candidate en minimisant une fonction de coût basée sur des potentiels statistiques DOPE. L'évaluation du programme montre un succès partiel lors des tests de contrôle (auto-threading de 5PTI et 1CTF), ainsi qu'une capacité à discriminer, légèrement, les protéines homologues (myoglobines 1MBA et 1MBD) des structures non apparentées (phycocyanine 1CPC). Néanmoins, l'analyse souligne les limites de cette implémentation, notamment un temps d'exécution élevé dû à une complexité algorithmique accrue et des biais de programmation.

## *Lien github du programme :*

[https://github.com/imanebiyarib-spec/DoubleDynamique Programation](https://github.com/imanebiyarib-spec/DoubleDynamiqueProgramation)

## Introduction

La structure d'une protéine détermine sa fonction et donc son rôle biologique. C'est pourquoi obtenir efficacement la conformation tridimensionnelle d'une protéine à partir de sa séquence 1D d'acide aminé demeure l'un des enjeux majeurs des recherches de biologies structurales.

Bien que le repliement natif d'une protéine correspond généralement à un état d'énergie minimale, l'exploration complète de l'espace

conformationnel ( $\sim 10^{\text{taille de la séquence}}$ ) est computationnellement impossible.

Cependant, il a été observé que des repliements similaires sont souvent partagés par différentes protéines, même en l'absence d'une forte similarité de séquence. Si la modélisation par homologie classique requiert un fort pourcentage d'identité pour être performante, les méthodes de threading (reconnaissance de repliements) permettent de surmonter cette limitation en enfilant directement la séquence cible sur le squelette d'une structure candidate.

Pour ce faire, l'algorithme teste itérativement l'ancrage de chaque résidu ( $n$ ) de la séquence ( $N$ ) sur chaque position ( $m$ ) de la structure ( $M$ ). Pour chaque ancre ( $m, n$ ), l'outil utilise l'algorithme d'alignement global de Needleman&Wunsch (1) pour remplir une matrice dite de "bas niveau" ( $L$ ) et trouver le chemin d'alignement optimal minimisant la fonction de coût. La méthode originale prend en compte l'énergie d'interaction des résidus, le potentiel de solvation et intègre des pénalités de gaps dépendantes de la structure secondaire, ainsi qu'un malus pour les chemins aberrants. Les scores des chemins optimaux de chaque matrice  $L$  sont ensuite accumulés dans une matrice globale de "haut niveau" ( $H$ ). Une seconde exécution de l'algorithme de Needleman&Wunsch utilise cette matrice  $H$  pour générer l'alignement optimal final dans la matrice  $F$ . Malgré des astuces permettant de restreindre l'espace de recherche, comme la sélection d'ancres probables et la méthode de Gotoh (2) pour Needleman&Wunsch, cette approche reste algorithmiquement coûteuse avec une complexité de  $O(M^2 N^2)$  où  $M$  et  $N$  représentent respectivement la longueur de la structure et de la séquence.

Ce rapport présente l'implémentation, en Python, de l'outil THREADER (3). Le protocole se veut fidèle à la méthode originale tout en adaptant certains aspects de conception.

Les performances de l'outil sont évaluées sur deux principes: la validation algorithmique par auto-threading et l'évaluation prédictive par threading d'homologie. Enfin, la discussion mettra en évidence les différences entre l'approche originale et cette implémentation afin d'expliquer les résultats obtenus et d'en souligner les limites computationnelles.

## **Matériels et Méthodes**

### **Acquisition des données**

Les séquences (format FASTA) et les structures (format PDB) de cinq protéines, analysées dans l'article de Jones&Taylor (1992, (4)), ont été extraites de la Protein Data Bank.

Les protéines 5PTI (58 résidus, (5)) et 1CTF (68 résidus, (6)) ont été utilisées comme contrôles positifs pour valider la robustesse géométrique de l'implémentation.

Les protéines 1CPC (162 résidus, (7)), 1MBA (146 résidus, (8)) et 1MBD (153 résidus, (9)) ont servi à évaluer la prédiction par homologie (prendre la séquence d'une protéine et de l'aligner sur la structure 3D d'une protéine différente mais proche évolutivement).

Les protéines 1MBA et 1MBD (en hélices alpha) sont des Myoglobines tandis que la phycocyanine (1CPC) est une protéine d'algue et possède des repliements similaires.

Un fichier DOPE.par (10), contenant les pseudos énergies DOPE précalculées en fonction de la distance en Angstrom pour un couple d'atome de résidus, sera utilisé dans la fonction de coût des matrices de bas niveau L.

### **Environnement**

Le script a été développé en Python (version 3.14.7). Les bibliothèques de base ont été utilisées et le package numpy (version 2.5.3) a été installé.

### **Algorithme**

*Gestion des fichiers d'entrée*

Le fichier DOPE.par a été filtré afin de ne retenir que les potentiels interactions entre carbones alpha (CA-CA).

Depuis les fichiers PDB, seuls les atomes alpha (CA) de la chaîne d'intérêt ont été extraits. L'index du résidu, son code 3 lettres, ses coordonnées x,y,z ainsi que son assignation de structure secondaire (hélice, feuillet ou boucle) ont été sauvegardés.

Enfin, la séquence de la chaîne de la protéine, spécifiée dans la ligne de commande, a été extraite du fichier FASTA.

### *Fonctions de coûts et pénalités*

Afin de rester fidèle à l'approche de THREADER, les pénalités de gap ont été paramétrées selon la structure secondaire : un coût de 2.0 est appliqué pour une insertion/délétion dans une boucle, contre un coût plus important de 20.0 pour la rupture d'une hélice ou d'un feuillet. Une pénalité U de 9999.0 a été assigné pour forcer le chemin à passer par l'ancre.

Deux fonctions de coûts ont été renseignées.

Lors du calcul de la matrice L, la fonction retourne un score nul sur l'ancre, le score DOPE de la distance correspondante pour les cases autorisées ( $p > m$  et  $q > n$  OU  $p < m$  et  $q < n$ ) et la pénalité U pour le reste de la matrice. Pour le tracé final dans la matrice F, la fonction de coût retourne simplement la valeur accumulée dans la matrice  $H[p][q]$ .

### *Double Programmation dynamique*

L'algorithme d'alignement global Needleman&Wunsch a été implémenté pour parcourir les séquences du C-terminal vers le N-terminal et pour chercher, dynamiquement, le nombre de gaps minimisant la fonction de coût. Pour chaque ancre probable, la matrice de bas niveau L est calculée et son chemin optimal est extrait.

Un ancre probable est défini comme suit : pour chaque position structurale m, une position n théorique dans la séquence ( $n\_expected$ ) est

déterminée. Seules les paires (m, n) situées dans une fenêtre autour de cette diagonale (la fenêtre d'exploration minimale est de 15 résidus, sinon elle est de 20% la longueur de la séquence) sont évaluées.

Afin de filtrer les chemins optimaux, seuls ceux possédant un score strictement inférieur à 500 sont ajoutés dans H.

### *Evaluation*

Un fois la matrice F remplie, l'alignement optimal, son score, le RMSD calculé ainsi que le temps d'exécution sont sauvegardés.

Le RMSD de la structure prédite par rapport à la structure native a été calculé selon l'algorithme de Kabsch (11). Les résidus assignés à des gaps, ne possédant pas de coordonnées tridimensionnelles, sont exclus de cette superposition.

### **Résultats**

#### **Complexité**

Comme souligné précédemment, la complexité théorique de l'outil TREADER est de  $O(M^2 N^2)$  où M et N représentent respectivement la longueur de la structure et de la séquence.

Cependant, la complexité de l'implémentation présentée est de  $O(M^2 N^2 (M+N))$ . Cette augmentation s'explique par le fait que l'algorithme de Needleman&Wunsch implémenté n'utilise pas l'algorithme de Gotoh et scanne itérativement toutes les longueurs de sauts possibles

|      |      |             |        |      |
|------|------|-------------|--------|------|
| 1MBD | 1MBA | -1572786.27 | 7.440  | 1h28 |
| 1CPC | 1MBA | -1464143.56 | 19.525 | 1h43 |
| 1CPC | 1MBD | -1427953.97 | 21.691 | 1h38 |

**Tableau 1 : Évaluation des performances de l'algorithme de double programmation dynamique pour l'alignement séquence structure**

*Les tests d'auto-threading (5PTI, 1CTF) servent de validation algorithmique.*

*Les tests de threading d'homologie (1MBA, 1MDB et 1CPC) évaluent la capacité de la fonction de score DOPE à identifier le meilleur gabarit structural.*

*Le score DOPE, le temps d'exécution ainsi que le RMSD, en Angstrom, ont été reportés.*

#### **Alignements**

##### *5PTI*

```
RPDFCLEPPYTGPCKARIIRYFYNAGAGLCQTFVYGGCRAKRNNFSAEDCMRTCGGA
RPDFCLEPPYTGPCKARIIRYFYNAGAGLCQTFVYGGCRAKRNNFSAEDCMRTCGGA
CHHHHHHCCCCCCCCCEEEEECCCCCEEEEECCCCCCCCCECHHHHHHHHHHCC
```

##### *1CTF*

```
AAEEKTEFDVILKAAGANKVAVIKAVRGATGLGLKEAKDLVESAPAALKEGVSKDDAEALKKALEEAGAEVEVK
EFDVILKAAGANKVAVIKAVRGATGL-----GLKEAKDLVESAPAALKEGVSKDDAEALKKALEEAGAEVEVK
CEEEEEEECCCHHHHHHHHHHHHHHHHC-----HHHHHHHHHHHCCCEEEEEHHHHHHHHHHHHHHHHHCCEEEEE
```

**Figure 1 : Alignements séquence structure générés lors de la validation algorithmique par auto-threading**

*La première ligne est la séquence de la cible tandis que la seconde est la séquence de la structure. La dernière ligne représente les structures secondaires correspondantes (H: Hélice, E: Feuillet, C: Boucle). Les insertions/délétions (gaps) sont représentés par des '--'.*

#### **Discussion**

**Validation de l'implémentation (Auto-threading)**

| Séquence | Structure | Score       | RMSD   | Temps |
|----------|-----------|-------------|--------|-------|
| 5PTI     | 5PTI      | -67019.690  | 0.000  | 1 min |
| 1CTF     | 1CTF      | -124364.370 | 7.676  | 2 min |
| 1MBA     | 1MBD      | -1277889.08 | 7.573  | 1h30  |
| 1MBA     | 1CPC      | -1256520.93 | 19.166 | 1h45  |
| 1MBD     | 1CPC      | -1233626.77 | 21.358 | 1h41  |

L'auto-threading consiste à enfiler une séquence sur sa propre structure native. Si l'implémentation est de bonne qualité, l'algorithme doit retrouver la structure native.

L'analyse sur 5PTI aboutit à une superposition parfaite (RMSD de 0.000 Å, score DOPE très négatif de  $-6.7 \times 10^4$ ) et prouve que la fonction de coût permet bien de minimiser la pseudo énergie de l'alignement. Cependant, l'expérience sur 1CTF est moins concluante (RMSD de 7.676 Å). Cela s'explique, dans un premier temps, par la différence du nombre de résidus dans la séquence et dans la structure malgré la vérification de la bonne sélection des fichiers et de la chaîne d'intérêt. Dans un second temps, une erreur d'implémentation, discutée en détail dans la suite de la discussion, encourage les insertions/délétions au centre des séquences et non dans les terminaisons.

### **Évaluation prédictive (Threading d'homologie)**

Le croisement de structures visait à tester le pouvoir discriminant du score statistique DOPE. Les myoglobines 1MBA et 1MBD présentent de bons scores de compatibilité (score DOPE  $\sim -12 \times 10^5$ ) avec un RMSD autour de 7.5 Å. La phycocyanine (1CPC), structure non homologue utilisée ici comme contrôle négatif, mène à des prédictions avec des RMSD supérieurs à 19 Å. Cependant, les scores DOPE restent très négatifs. Cela est dû à la manière dont la matrice H additionne les scores des alignements optimaux et sera discutée dans les limites.

### **Limites**

Les énergies DOPE rapportées sont particulièrement négatives ( $\sim -10^6$ ). Comme expliqué précédemment, ce phénomène est dû à la conception de la matrice H qui accumule (additionne) les scores de tous les chemins optimaux superposés. Le score final contenu dans la matrice F croît donc proportionnellement au nombre d'ancres

explorées et à la taille de la protéine plutôt que de refléter une pseudo énergie de compatibilité.

L'analyse des alignements (Figure 1 et Annexe 1) révèle que les gaps sont systématiquement au centre de la séquence et n'apparaissent jamais aux extrémités N ou C terminales. Ce comportement est la conséquence de l'initialisation des marges de l'algorithme d'alignement global, qui pénalise les gaps terminaux de manière linéaire. Ainsi, une insertion de 5 résidus sera 5 fois plus coûteuse dans les marges qu'à l'intérieur des séquences. Cela contraint l'algorithme à concentrer les décalages importants dans les boucles internes, expliquant, en partie, le RMSD non nul (7.6 Å) observé lors de l'auto-threading de 1CTF.

De plus, outre la complexité computationnelle accrue qui a empêché le calcul de zscores par shuffling de séquences aléatoires, l'évaluation géométrique repose sur une correspondance d'index directe entre deux structures. La génération d'un fichier PDB intégrant une modélisation de boucle pour les gaps aurait permis une superposition structurale plus précise sous PyMOL. Les hyperparamètres (pénalités, taille de fenêtre, seuil d'accumulation dans H) nécessiteraient une étude d'optimisation pour maximiser la sensibilité de la prédiction.

À ces limites s'ajoutent deux contraintes. D'une part, l'algorithme de Needleman&Wunsch implémenté n'applique pas l'astuce de Gotoh pour le traitement des gaps faisant passer la complexité attendue de  $O(M^2N^2)$  à  $O(M^2N^2(M+N))$ . D'autre part, une confrontation de nos résultats avec l'exécution de l'outil THREADER original n'a pas été possible étant donné que le lien de l'implémentation dans la publication est obsolète.

### **Références**

- 1- Needleman, S. B., & Wunsch, C. D. (1970). A general method applicable to the search for

similarities in the amino acid sequence of two proteins. *Journal of molecular biology*, 48(3), 443-453.

2- Gotoh, O. (1982). An improved algorithm for matching biological sequences. *Journal of molecular biology*, 162(3), 705-708.

3- Jones, D.T. (1998) **THREADER** : Protein Sequence Threading by Double Dynamic Programming. (in) *Computational Methods in Molecular Biology*. Steven Salzberg, David Searls, and Simon Kasif, Eds. Elsevier Science. Chapter 13.

4- Jones, D.T., Taylor, W.R. & Thornton, J.M. (1992) A new approach to protein fold recognition. *Nature*. 358, 86-89.

5- Wlodawer, A., Walter, J., Huber, R., & Sjolín, L. (1984). **5PTI** : Structure of bovine pancreatic trypsin inhibitor. Results of joint neutron and X-ray refinement of crystal form II. *J Mol Biol*, 180, 301-329. [https://doi.org/10.1016/s0022-2836\(84\)80006-6](https://doi.org/10.1016/s0022-2836(84)80006-6)

6- Leijonmarck, M., & Liljas, A. (1987). **1CTF** : Structure of the C-terminal domain of the ribosomal protein L7/L12 from *Escherichia coli* at 1.7 Å. *J Mol Biol*, 195, 555-579. [https://doi.org/10.1016/0022-2836\(87\)90183-5](https://doi.org/10.1016/0022-2836(87)90183-5)

7- Duerring, M., Schmidt, G. B., & Huber, R. (1991). **1CPC** : Isolation, crystallization, crystal structure analysis and refinement of constitutive C-phycoerythrin from the chromatically adapting cyanobacterium *Fremyella diplosiphon* at 1.66 Å resolution. *J Mol Biol*, 217, 577-592. [https://doi.org/10.1016/0022-2836\(91\)90759-y](https://doi.org/10.1016/0022-2836(91)90759-y)

8- Bolognesi, M., Onesti, S., Gatti, G., Coda, A., Ascenzi, P., & Brunori, M. (1989). **1MBA** : *Aplysia limacina* myoglobin. Crystallographic analysis at 1.6 Å resolution. *J Mol Biol*, 205, 529-544. <https://www.rcsb.org/>

9- Phillips, S. E. (To be published). **1MBD** : X-ray structure of sperm whale deoxymoglobin refined at 1.4 Å resolution.

10- <http://www.dsimb.inserm.fr/~gelly/doc/dope.par>

11-Kabsch, W. (1976). A solution for the best rotation to relate two sets of vectors. *Foundations of Crystallography*, 32(5), 922-923.

### Enfilage de ICPC sur IMBA

### Enfilage de IMBA sur IMBD

### Enfilage de IMBD sur IMBA

*La première ligne est la séquence de la cible tandis que la seconde est la séquence de la structure. La dernière ligne représente les structures secondaires correspondantes (H: Hélice, E: Feuillet, C: Boucle). Les insertions/délétions (gaps) sont représentés par des '--'.*